



基于多尺度空谱特征的高光谱影像分类研究

(申请武汉大学测绘工程专业硕士学位答辩报告)

答辩人：王迪

指导人：史磊 副教授、张良培 教授

杜博 教授



智能感知与机器学习组
二〇二〇年五月

目录

1 研究背景

- 高光谱图像分类
- 存在的问题
- 解决方法
- 研究现状

2 研究路线

3 研究内容

- 多尺度混合补偿网络

■ 混合信息感知网络

- 自适应空谱多尺度网络
- 模型对比及分析

4 研究总结

5 参考文献

6 研究成果

7 感谢

目录

1 研究背景

- 高光谱图像分类
- 存在的问题
- 解决方法
- 研究现状

2 研究路线

3 研究内容

- 多尺度混合补偿网络

■ 混合信息感知网络

■ 自适应空谱多尺度网络

■ 模型对比及分析

4 研究总结

5 参考文献

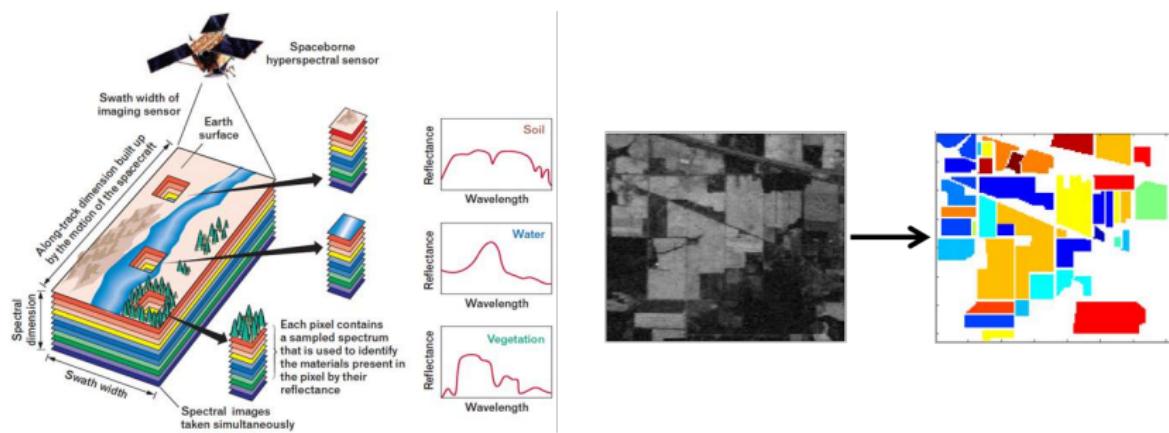
6 研究成果

7 感谢



高光谱图像分类

随着传感器技术的发展，能够获得具有许多波段的高光谱图像。高光谱图像分类就是对图像中的每个像素赋予一个唯一的语义标签



目录

1 研究背景

- 高光谱图像分类
- 存在的问题
- 解决方法
- 研究现状

2 研究路线

3 研究内容

- 多尺度混合补偿网络

■ 混合信息感知网络

■ 自适应空谱多尺度网络

■ 模型对比及分析

4 研究总结

5 参考文献

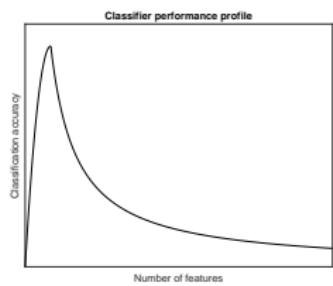
6 研究成果

7 感谢

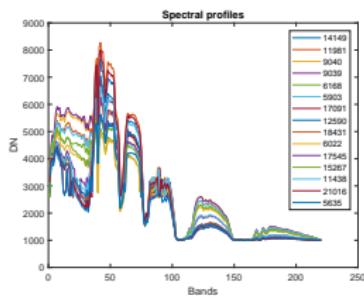


存在的问题

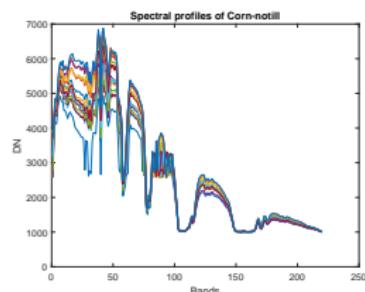
存在的问题



维数灾难



光谱冗余



空间变异

目录

1 研究背景

- 高光谱图像分类
- 存在的问题
- 解决方法
- 研究现状

2 研究路线

3 研究内容

- 多尺度混合补偿网络

■ 混合信息感知网络

- 自适应空谱多尺度网络
- 模型对比及分析

4 研究总结

5 参考文献

6 研究成果

7 感谢



解决方法



传统思路

应对维数灾难

降维：特征选择、特征提取 (PCA、ICA)

应对光谱冗余和空间变异

多特征空谱融合：特征工程 (EMP、SP、SR、滤波器)、预分类优化

- 依赖于设计者
- 浅层特征，识别力有限



解决方法



深度学习技术

优势

- 深层特征
- 自动化提取
- 端到端

典型应用

- DNN[1], [2]: SAE、DBN(丢失空间信息)
- CNN[3]: 局部感知、权重共享、保持空间结构
- 序列模型 [4], [5]: RNN 及其变种 LSTM、GRU



研究现状

目录

1 研究背景

- 高光谱图像分类
 - 存在的问题
 - 解决方法
 - 研究现状

2 研究路线

3 研究内容

- ## ■ 多尺度混合补偿网络



- 混合信息感知网络
 - 自适应空谱多尺度网络
 - 模型对比及分析

4 研究总结

5 参考文献

6 研究成果



研究现状

研究现状

原有空间多尺度
特征提取方法

原有空间上下文
信息提取方法

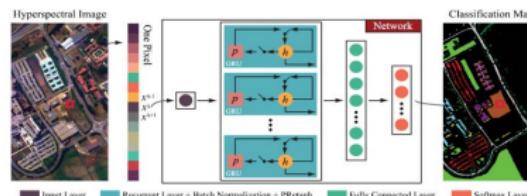
原有光谱上下文
信息提取方法



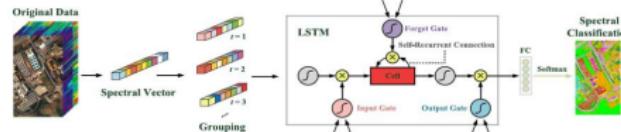
研究现状

光谱上下文信息提取

高光谱图像的光谱分辨率非常高，这意味着狭窄的波长范围内聚集着大量的波段，这些波段之间往往具有很强的联系。在高光谱图像分类领域，这种联系往往基于 RNN 进行提取。在遥感影像中，上下文信息具有物理意义。



Mou et al, 2017[6]

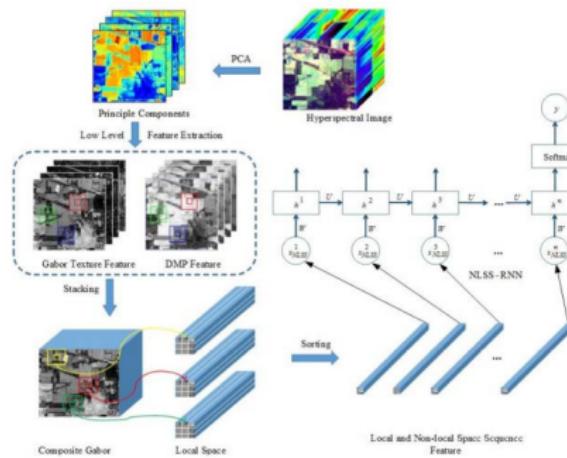


Xu et al, 2018[7]



研究现状

空间上下文信息提取



Zhang et al, 2018[8]

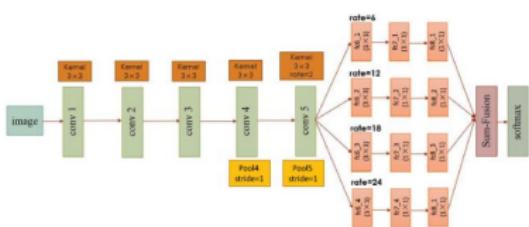
通过中心像素与八邻域像素在特征空间的欧氏距离确定相关度，并根据相关程度确定输入 RNN 的时间步顺序。**(损失了空间结构)**



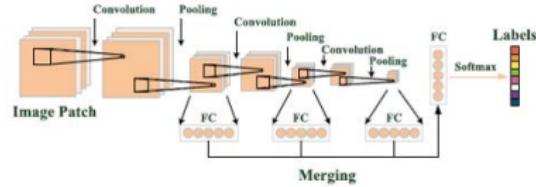
研究现状

空间多尺度信息提取

- (a) 并行，不同卷积核 (Inception[9]、ASPP[10])
 (b) 串行



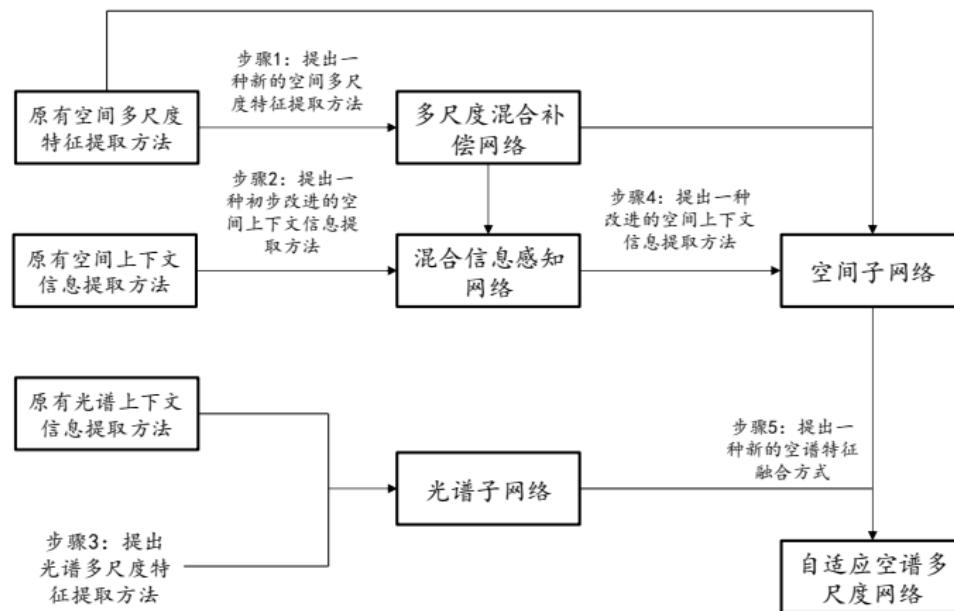
(a) Niu et al, 2019[11]



(b) Xu et al, 2018[7]



研究路线



多尺度混合补偿网络

目录

1 研究背景

- 高光谱图像分类
- 存在的问题
- 解决方法
- 研究现状

2 研究路线

3 研究内容

- 多尺度混合补偿网络

■ 混合信息感知网络

- 自适应空谱多尺度网络
- 模型对比及分析

4 研究总结

5 参考文献

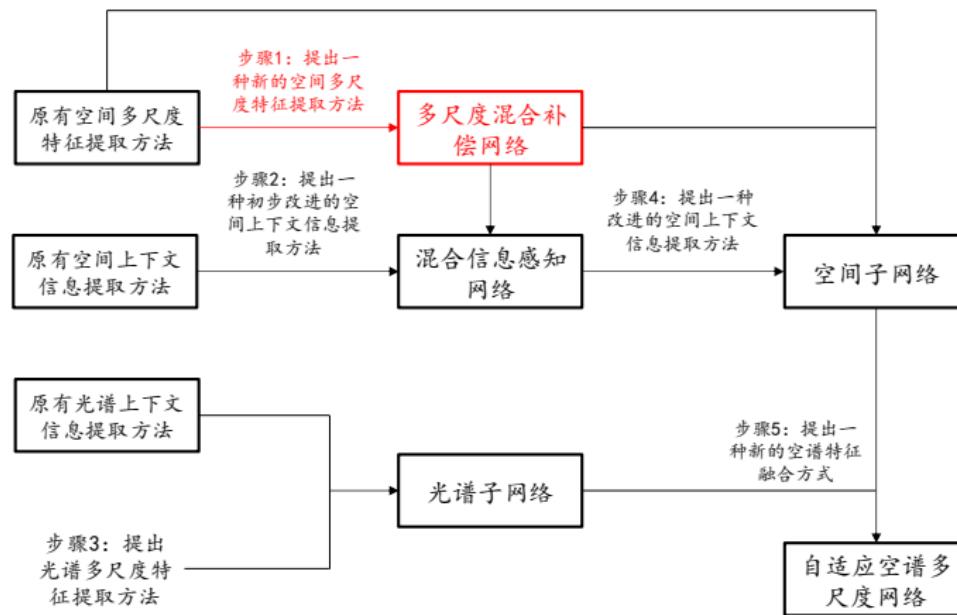
6 研究成果

7 感谢



多尺度混合补偿网络

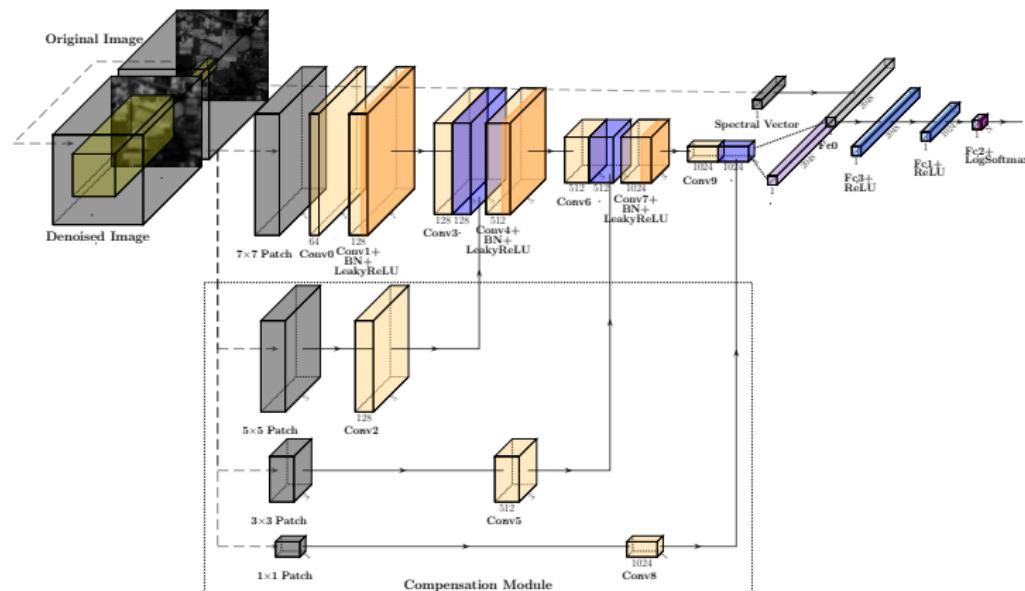
研究路线





多尺度混合补偿网络

模型





多尺度混合补偿网络

实验

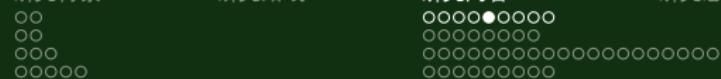
PU 数据集

- 尺寸 $610 \times 340 \times 103$, 9 个地物类别
- 每类随机选 100 个样本组成训练集

Groundtruth classes for the Pavia University scene and their respective samples number

#	Class	Samples
1	Asphalt	6631
2	Meadows	18649
3	Gravel	2099
4	Trees	3064
5	Painted metal sheets	1345
6	Bare Soil	5029
7	Bitumen	1330
8	Self-Blocking Bricks	3682
9	Shadows	947





多尺度混合补偿网络

实验

PU: 610 × 340 × 103, 9 类

训练集：每类随机选 100 个样本

不同算法在 PU 数据集上的分类精度 (%)

	CNN	FEFCN-ELM [12]	SSRN[13]	DPRN[14]	MSCN	ICA-MSHCN	PCA-MSHCN	ORI-MSHCN
OA	89.09	91.50	97.66	97.40	97.17	97.57	97.49	97.80
	± 9.05	±1.31	±1.34	±5.16	±0.69	±0.43	±0.71	±0.43
AA	92.66	91.92	96.97	96.54	97.50	97.70	97.69	97.75
	± 3.52	±0.57	±1.70	±6.12	±0.89	±0.57	±0.52	±0.48
Kappa	86.17	88.84	96.90	96.60	96.24	96.76	96.66	97.06
	± 10.76	±1.64	±1.74	±6.73	±0.91	±0.58	±0.94	±0.59

○○
○○
○○○
○○○○

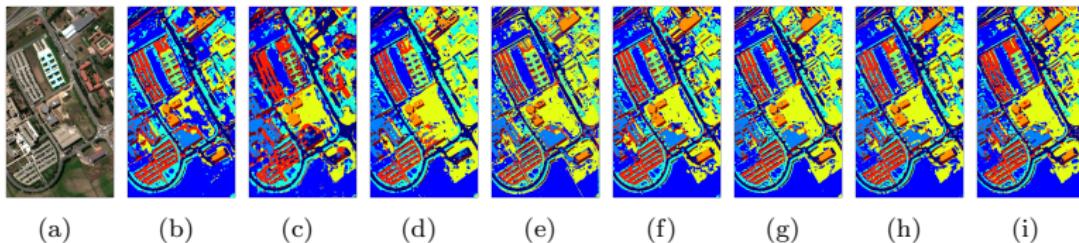
○○○○●○○○
○○○○○○○○
○○○○○○○○○○○○○○○○
○○○○○○○○○

多尺度混合补偿网络

实验

PU: $610 \times 340 \times 103$, 9 类

训练集: 每类随机选 100 个样本



不同方法在 PU 数据集上的分类结果: (a) 原始图像 (b) CNN (c) FEFCN-ELM (d) SSRN
(e) DPRN (f) MSCN (g) ICA-MSHCN (h) PCA-MSHCN (i) ORI-MSHCN.

○○
○○
○○○
○○○○

○○○○○●○○
○○○○○○○
○○○○○○○○○○○○○○○○
○○○○○○○○

多尺度混合补偿网络

实验



UNIVERSITY of HOUSTON
Cullen College of Engineering
Department of Electrical & Computer Engineering

NCALM
The National Center for Airborne Laser Mapping
University of Houston + University of California, Berkeley

DIGITALGLOBE®



UH 数据集

- 尺寸 $349 \times 1905 \times 144$, 15 个地物类别
- 每类随机选 100 个样本组成训练集

多尺度混合补偿网络



实验

UH: $349 \times 1905 \times 144$, 15 类

训练集: 每类随机选 100 个样本

不同算法在 UH 数据集上的分类精度 (%)

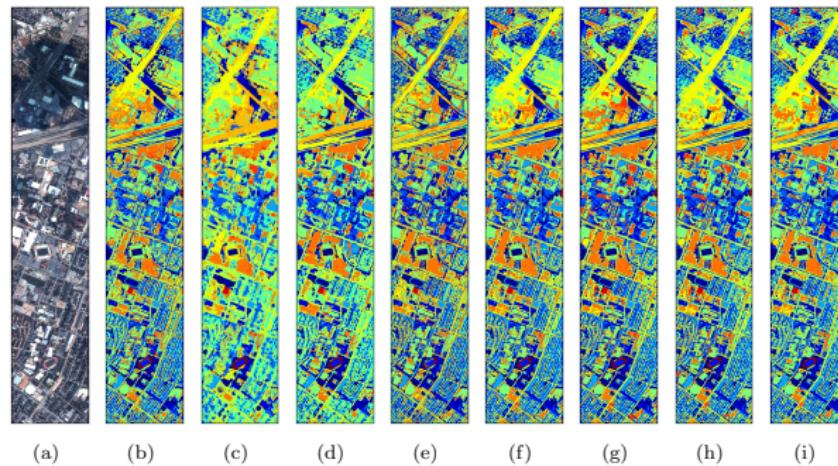
	CNN	FEFCN-ELM [12]	SSRN[13]	DPRN[14]	MSCN	ICA-MSHCN	PCA-MSHCN	ORI-MSHCN
OA	91.29	96.36	98.59	96.55	96.97	96.91	97.49	96.78
	±3.29	±1.17	±0.46	±1.73	±1.39	±1.31	±0.88	±1.23
AA	92.84	95.39	98.54	96.65	97.42	97.41	97.88	97.18
	±2.61	±1.01	±0.59	±1.75	±1.06	±1.05	±0.72	±1.09
Kappa	90.56	96.06	98.47	96.27	96.72	96.67	97.28	96.51
	±3.57	±1.43	±0.50	±1.87	±1.50	±1.42	±0.96	±1.33

○○
○○○
○○○○
○○○○○

多尺度混合补偿网络

实验

UH: $349 \times 1905 \times 144$, 15 类
训练集: 每类随机选 100 个样本



不同方法在 UH 数据集上的分类结果: (a) 原始图像 (b) CNN (c) FEFCN-ELM (d) SSRN
(e) DPRN (f) MSCN (g) ICA-MSHCN (h) PCA-MSHCN (i) ORI-MSHCN.



混合信息感知网络

研究路线

研究内容

研究总结

参考文献

研究成果

感谢

目录

1 研究背景

- 高光谱图像分类
- 存在的问题
- 解决方法
- 研究现状

2 研究路线

3 研究内容

- 多尺度混合补偿网络

■ 混合信息感知网络

- 自适应空谱多尺度网络
- 模型对比及分析

4 研究总结

5 参考文献

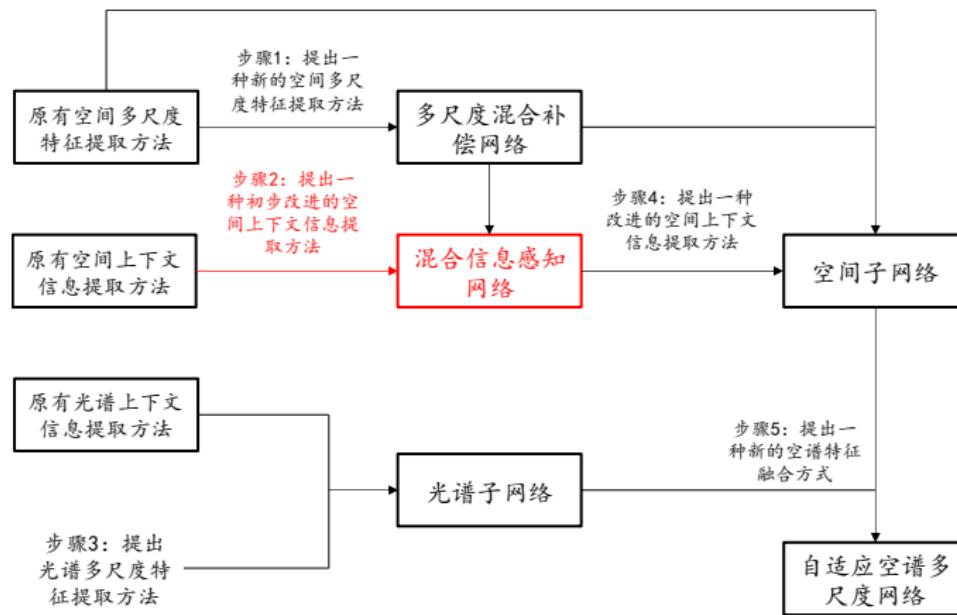
6 研究成果

7 感谢



混合信息感知网络

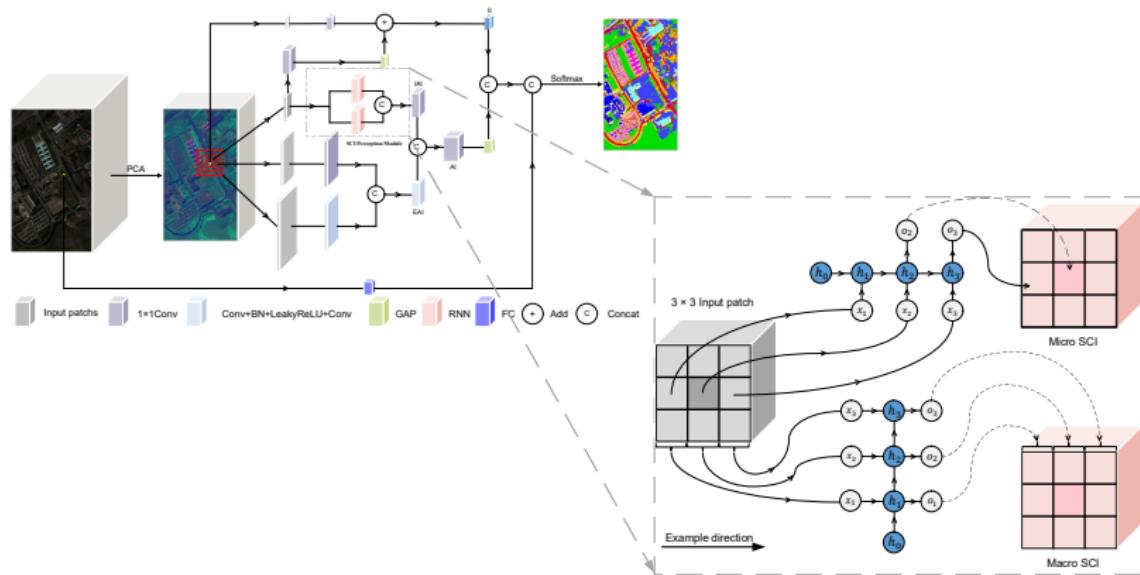
研究路线





混合信息感知网络

模型



混合信息感知网络



实验

PU: $610 \times 340 \times 103$, 9 类

训练集：每类随机选 100 个样本

不同算法在 PU 数据集上的分类精度 (%)

	3DCNN	SSRN	CNN	LSS -RNN	HPN -RNN	HPN -LSTM	HPN -GRU	SS-HPN -RNN	SS-HPN -LSTM	SS-HPN -GRU
OA	87.71	97.66	97.46	97.98	98.08	98.21	97.99	98.09	98.22	98.00
	± 1.75	± 1.34	± 0.79	± 0.73	± 0.58	± 0.49	± 0.67	± 0.58	± 0.66	± 0.72
AA	90.46	96.97	97.76	98.23	98.28	98.19	98.28	98.29	98.27	97.88
	± 0.89	± 1.70	± 0.62	± 0.83	± 0.25	± 0.52	± 0.34	± 0.35	± 0.65	± 0.83
Kappa	83.81	96.90	96.63	97.31	97.44	97.61	97.32	97.45	97.62	97.33
	± 2.03	± 1.74	± 1.05	± 0.97	± 0.77	± 0.66	± 0.88	± 0.77	± 0.87	± 0.96

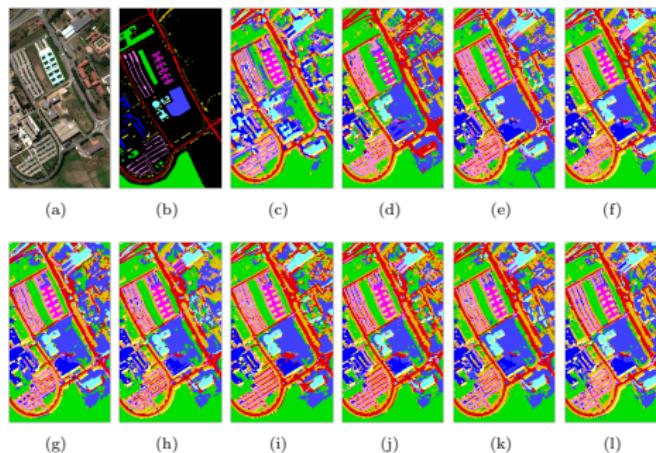
10

混合信息感知网络

实验

PU: 610 × 340 × 103, 9 类

训练集：每类随机选 100 个样本



不同方法在 PU 数据集上的分类结果: (a) 原始图像. (b) 地物标签. (c) 3DCNN. (d) SSRN. (e) CNN. (f) LSS-RNN. (g) HPN-RNN. (h) HPN-LSTM. (i) HPN-GRU. (j) SS-HPN-RNN. (k) SS-HPN-LSTM. (l) SS-HPN-GRU.

混合信息感知网络

实验

IP 数据集

- 尺寸 $145 \times 145 \times 220$,
16 个地物类别



Groundtruth classes for the Indian Pines scene and their respective samples number

#	Class	Samples
1	Alfalfa	46
2	Corn-notill	1428
3	Corn-mintill	830
4	Corn	237
5	Grass-pasture	483
6	Grass-trees	730
7	Grass-pasture-mowed	28
8	Hay-windrowed	478
9	Oats	20
10	Soybean-notill	972
11	Soybean-mintill	2455
12	Soybean-clean	593
13	Wheat	205
14	Woods	1265
15	Buildings-Grass-Trees-Drives	386
16	Stone-Steel-Towers	93

混合信息感知网络



实验

IP: $145 \times 145 \times 220$, 16 类

训练集：除第一、七、九、十六类分别选 33、20、14、75 个样本外，其余类每类随机选 100 个样本

不同算法在 IP 数据集上的分类精度 (%)

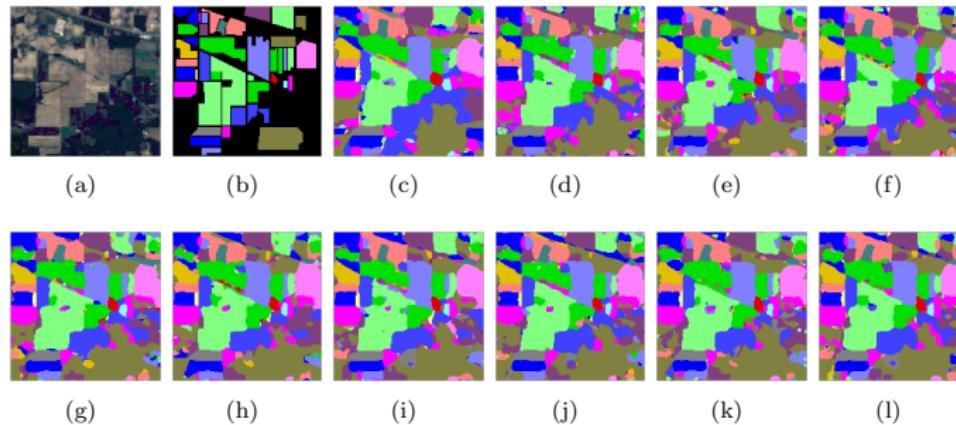
	3DCNN	SSRN	CNN	LSS -RNN	HPN -RNN	HPN -LSTM	HPN -GRU	SS-HPN -RNN	SS-HPN -LSTM	SS-HPN -GRU
OA	95.80 ±0.70	97.26 ±0.63	96.20 ±0.79	96.68 ±0.64	96.71 ±0.59	96.83 ±0.52	96.75 ±0.42	96.81 ±0.41	97.30 ±0.63	97.03 ±0.47
AA	97.98 ±0.26	96.20 ±1.10	98.47 ±0.39	98.64 ±0.18	98.70 ±0.28	98.74 ±0.17	98.74 ±0.13	98.76 ±0.14	98.86 ±0.29	98.79 ±0.17
Kappa	95.15 ±0.80	96.83 ±0.72	95.61 ±0.91	96.15 ±0.74	96.19 ±0.69	96.33 ±0.60	96.24 ±0.48	96.31 ±0.47	96.87 ±0.73	96.57 ±0.54

混合信息感知网络

实验

IP: $145 \times 145 \times 220$, 16 类

训练集：除第一、七、九、十六类分别选 33、20、14、75 个样本外，其余类每类随机选 100 个样本



不同方法在 IP 数据集上的分类结果: (a) 原始图像. (b) 地物标签. (c) 3DCNN. (d) SSRN.
 (e) CNN. (f) LSS-RNN. (g) HPN-RNN. (h) HPN-LSTM. (i) HPN-GRU. (j)
 SS-HPN-RNN. (k) SS-HPN-LSTM. (l) SS-HPN-GRU.



自适应空谱多尺度网络

研究路线

研究内容

研究总结

参考文献

研究成果

感谢



目录

1 研究背景

- 高光谱图像分类
- 存在的问题
- 解决方法
- 研究现状

2 研究路线

3 研究内容

- 多尺度混合补偿网络

■ 混合信息感知网络

■ 自适应空谱多尺度网络

■ 模型对比及分析

4 研究总结

5 参考文献

6 研究成果

7 感谢



自适应空谱多尺度网络

实验数据

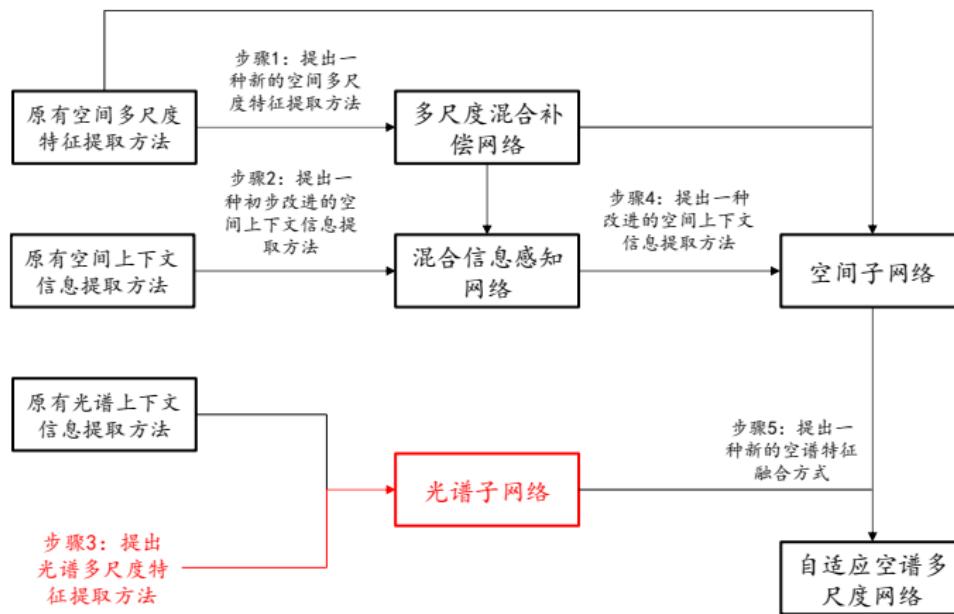
本节实验数据集：(a) IP. (b) PU. (c) KSC.

Dataset ID	Original Image and Ground Truth	Class ID	Color	Class Name	Training	Testing	Total
(a)		1		Alfalfa	33	13	46
		2		Corn-notill	100	1328	1428
		3		Corn-till	100	730	830
		4		Corn	100	137	237
		5		Grass-pasture	100	383	483
		6		Grass-trees	100	630	730
		7		Grass-pasture-mowed	20	8	28
		8		Hay-windrowed	100	378	478
		9		Oats	14	6	20
		10		Soybean-notill	100	872	972
		11		Soybean-till	100	2355	2455
		12		Soybean-clean	100	495	593
		13		Wheat	100	105	205
		14		Woods	100	1165	1265
		15		Buildings-Grass-Trees-Drives	100	286	386
		16		Stone-Steel-Towers	75	18	93
		Total			1342	8907	10249
(b)		1		Asphalt	100	6531	6631
		2		Meadows	100	18549	18649
		3		Gravel	100	1999	2099
		4		Trees	100	2964	3064
		5		Painted metal sheets	100	1245	1345
		6		Bare Soil	100	4929	5029
		7		Bitumen	100	1230	1330
		8		Self-Blocking Bricks	100	3582	3682
		9		Shadows	100	847	947
		Total			900	41876	42776
(c)		1		Scrub	33	728	761
		2		Willow swamp	23	220	243
		3		CP hammock	24	232	256
		4		Red Oak	24	76	82
		5		Slash pine	15	146	161
		6		Oak/Broadleaf	22	207	229
		7		Hardwood swamp	9	96	105
		8		Graminoid marsh	38	393	431
		9		Spartina marsh	51	469	520
		10		Cattail marsh	39	365	404
		11		Salt marsh	41	378	419
		12		Mud flats	49	454	503
		13		Water	91	836	927
		Total			459	4752	5211



自适应空谱多尺度网络

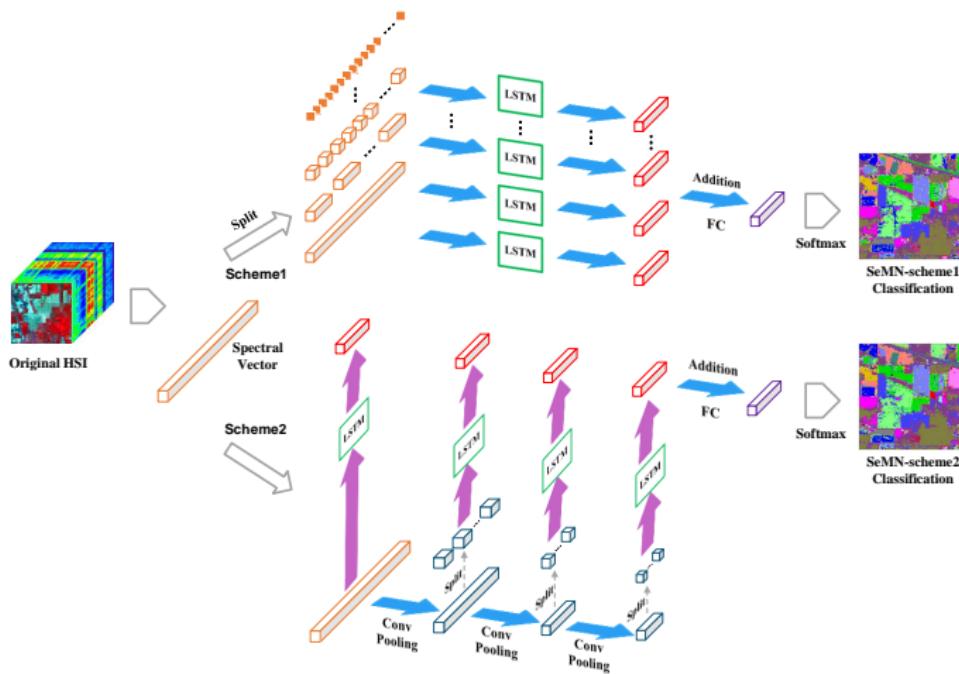
研究路线





自适应空谱多尺度网络

光谱子网络

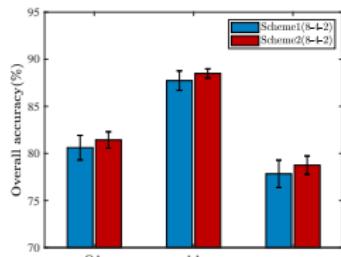


10

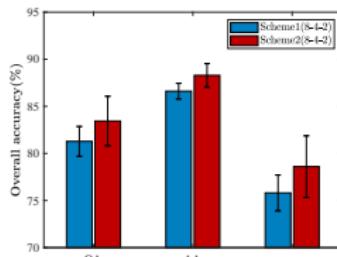
自适应空谱多尺度网络

光谱子网络

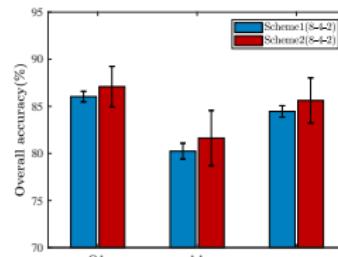
方案一 V.S. 方案二



(a)



(b)



(c)

方案一 (8-4-2) 与方案二 (8-4-2) 在三个数据集上的性能比较. (a) IP. (b) PU. (c) KSC.

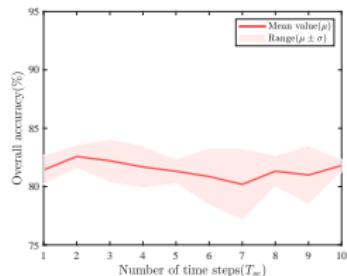
方案二优于方案一！



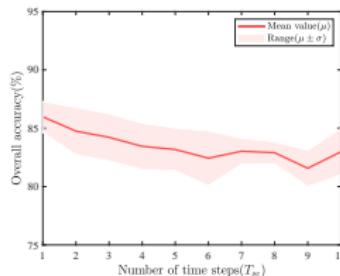
自适应空谱多尺度网络

光谱子网络

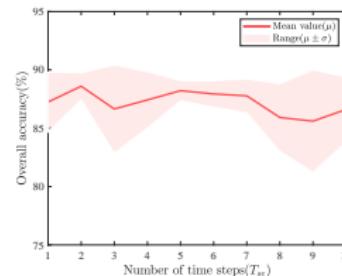
探究方案二特征图分组数 T_{se} 与分类精度的关系



(a)



(b)



(c)

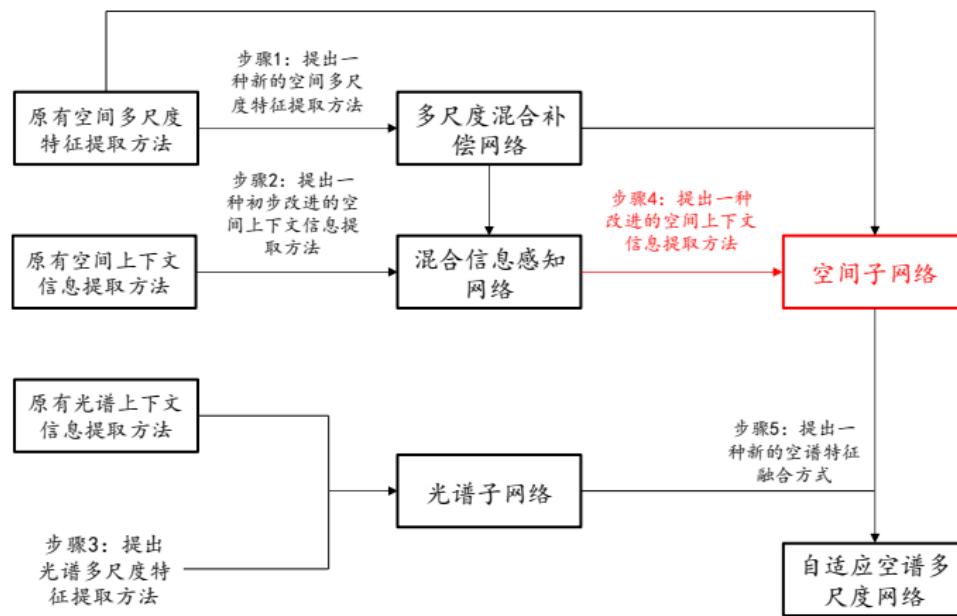
不同 T_{se} 下方案二在三个数据集上的表现. (a) IP. (b) PU. (c) KSC.

$$T_{se} = 2$$



自适应空谱多尺度网络

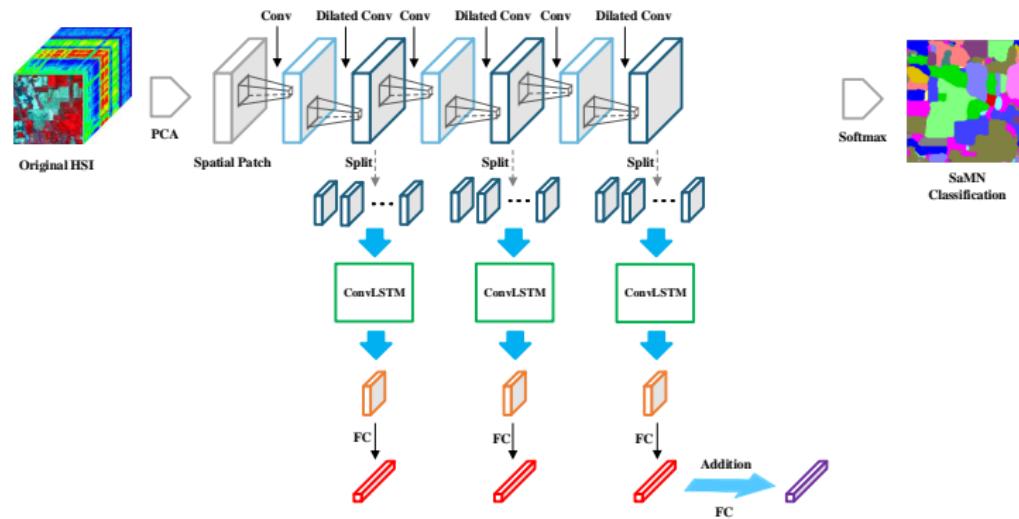
研究路线





自适应空谱多尺度网络

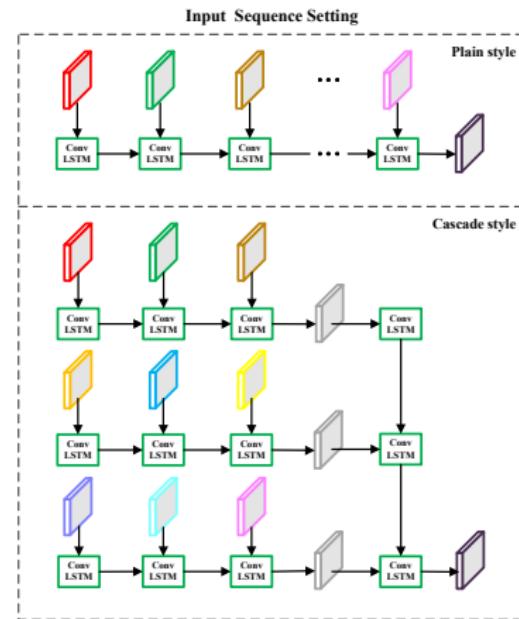
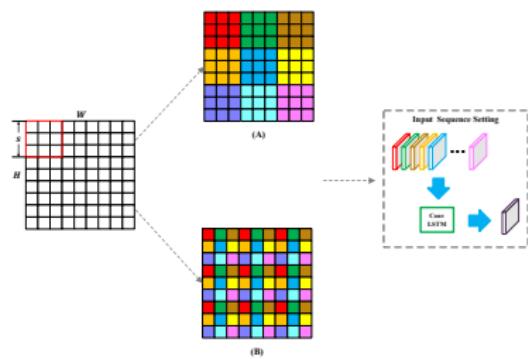
空间子网络





自适应空谱多尺度网络

空间子网络

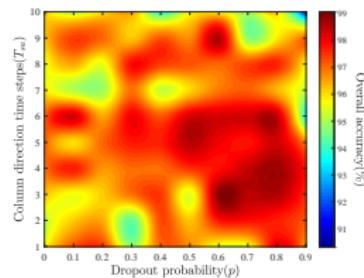




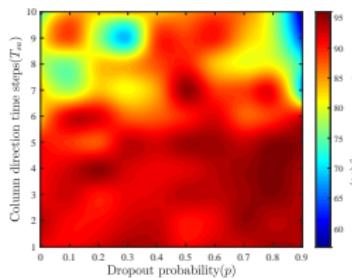
自适应空谱多尺度网络

空间子网络

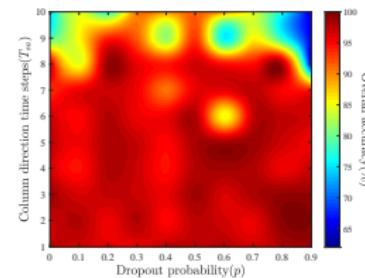
探究分组数 T_{sa} , 丢弃概率 p 与分类精度的关系



(a)



(b)



(c)

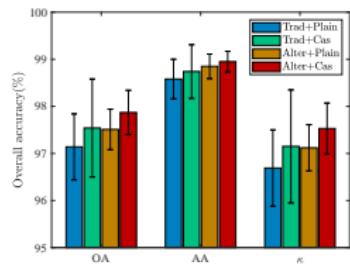
不同的 T_{sa} 和 p 下空间子网络在三个数据集上的表现. (a) IP. (b) PU. (c) KSC.

$$T_{sa} = 3, p = 0.8$$

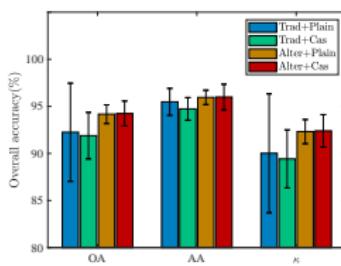
自适应空谱多尺度网络

空间子网络

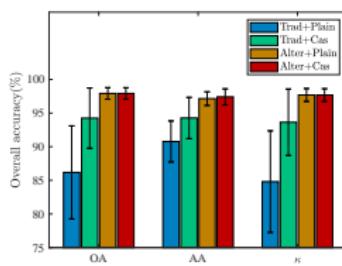
探究分组策略和序列输入设置的最佳组合



(a)



(b)



(c)

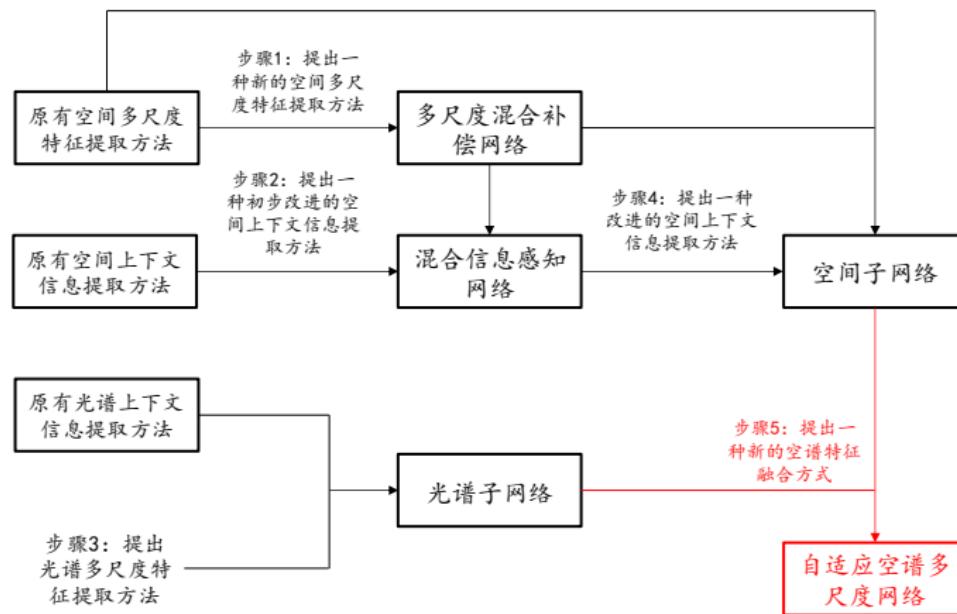
不同分组策略和输入序列设置下空间子网络在三个数据集上的表现 (a) IP. (b) PU. (c) KSC.

交替分组 + 级联输入更为有效!



自适应空谱多尺度网络

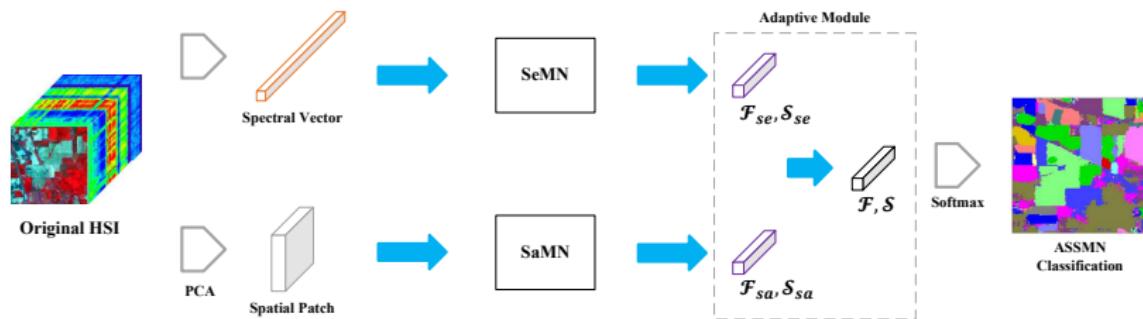
研究路线





自适应空谱多尺度网络

特征融合模块



- \mathcal{F}_* : 空间/光谱子网络提取到的空间/光谱特征
- \mathcal{S}_* : 由 \mathcal{F}_* 转换而成的分数向量



自适应空谱多尺度网络

特征融合模块

特征连接

$$\mathcal{F} = \text{Concat}(\mathcal{F}_{se}, \mathcal{F}_{sa})$$

$$\mathcal{S} = W\mathcal{F} + b$$

$$= W_1\mathcal{F}_{se} + W_2\mathcal{F}_{sa} + b_1 + b_2$$

$$= A_1 + b_1 + A_2 + b_2$$

特征加权相加

$$\mathcal{F} = F_s(m) \cdot \mathcal{F}_{se} + (1 - F_s(m)) \cdot \mathcal{F}_{sa}$$

$$\mathcal{S} = W\mathcal{F} + b$$

$$= F_s(m) \cdot W\mathcal{F}_{se} + (1 - F_s(m))$$

$$\cdot W\mathcal{F}_{sa} + b$$

分数加权相加

$$\begin{aligned} \mathcal{S} &= F_s(m)\mathcal{S}_{se} + (1 - F_s(m))\mathcal{S}_{sa} = F_s(m) \cdot W_{se}\mathcal{F}_{se} + (1 - F_s(m)) \cdot W_{sa}\mathcal{F}_{sa} + \\ &F_s(m) \cdot b_{se} + (1 - F_s(m)) \cdot b_{sa} = \lambda_1(A_1 + b_1) + \lambda_2(A_2 + b_2) \end{aligned}$$

自适应空谱多尺度网络

实验—IP 数据集

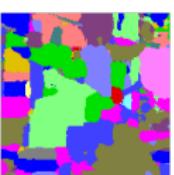
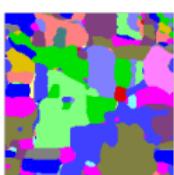
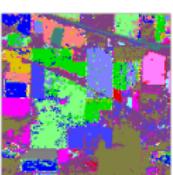
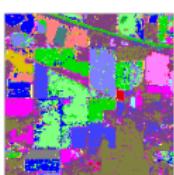
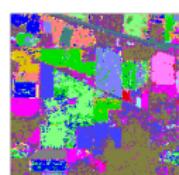
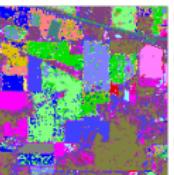
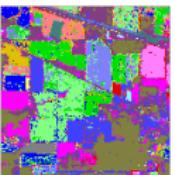
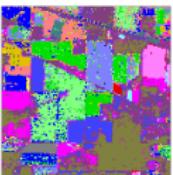
Class	Spectral						Spatial			Joint			
	SVM	1-DCNN	LSTM-strategy 1	LSTM-strategy 2	SeMN-scheme 1	SeMN-scheme 2	2-DCNN	MSCNN	SaMN	3-DCNN ¹	SSRN	SSUN	ASSMN
OA (%)	79.02	75.40	75.99	77.96	80.61	82.49	86.20	96.58	97.46	96.57	96.62	96.75	98.30
	±0.92	±4.18	±0.87	±2.04	±1.31	±0.86	±1.50	±0.79	±0.52	±1.12	±0.75	±0.65	±0.51
AA (%)	87.08	85.05	82.55	84.55	87.73	88.73	94.58	98.52	98.85	98.53	95.87	98.64	99.09
	±1.19	±1.77	±1.36	±1.74	±1.03	±1.30	±0.75	±0.30	±0.16	±0.41	±1.18	±0.23	±0.36
$\kappa \times 100$	76.04	72.06	72.63	74.81	77.83	79.94	84.20	96.05	97.05	96.04	96.09	96.24	97.03
	±1.04	±4.56	±0.99	±2.29	±1.45	±0.97	±1.69	±0.90	±0.60	±1.29	±0.86	±0.75	±0.59
T_{trn} (s)	0.14	255.91	119.45	118.95	177.19	218.75	57.42	100.70	1301.53	34686.45	869.76	216.98	1430.76
	±0.00	±3.16	±2.75	±3.16	±11.44	±2.64	±2.80	±5.57	±57.29	±1262.40	±31.28	±3.28	±43.07
T_{tes} (s)	1.68	0.46	2.05	1.90	0.53	0.52	1.17	1.83	5.14	144.42	4.02	2.77	4.75
	±0.02	±0.34	±0.83	±0.71	±0.07	±0.07	±0.59	±0.64	±1.34	±10.11	±0.33	±0.69	±1.07
1	94.62	89.23	81.54	87.69	92.31	90.00	100.00	100.00	100.00	100.00	100.00	100.00	99.23
2	75.02	72.97	69.98	72.15	74.74	77.68	82.27	95.86	94.33	94.65	95.26	95.74	96.48
3	76.51	74.01	73.51	75.66	76.90	76.03	92.92	97.16	98.55	97.30	96.96	97.55	98.68
4	90.00	84.31	84.31	85.62	88.25	89.05	99.64	99.85	100.00	100.00	95.20	100.00	99.71
5	92.98	90.99	89.90	88.83	92.09	93.52	93.58	98.62	99.37	98.98	98.88	97.96	98.88
6	95.11	94.14	91.16	92.57	94.54	95.62	96.52	99.02	99.37	99.57	98.51	99.67	99.97
7	90.00	95.00	88.75	90.00	91.25	90.00	100.00	100.00	100.00	100.00	95.71	100.00	98.75
8	97.86	97.94	95.34	95.48	97.96	98.28	99.63	99.95	100.00	100.00	100.00	100.00	100.00
9	90.00	85.00	73.33	81.67	95.00	93.33	100.00	100.00	100.00	100.00	100.00	100.00	100.00
10	79.64	78.97	79.79	81.69	85.38	87.02	89.39	95.67	96.59	96.66	87.79	95.92	98.20
11	64.64	59.71	63.49	68.06	69.54	72.41	69.85	93.46	96.41	93.88	99.01	93.71	97.29
12	84.89	82.76	75.88	83.57	84.91	87.81	96.31	98.50	97.81	98.34	96.59	99.23	99.23
13	98.95	99.14	98.48	96.29	98.19	99.24	99.90	100.00	100.00	100.00	99.89	100.00	99.52
14	88.87	77.48	85.05	82.11	87.12	88.44	93.93	98.55	99.23	97.76	99.54	98.52	99.45
15	76.40	79.65	73.04	71.92	78.85	81.33	99.37	99.72	100.00	99.97	94.10	100.00	100.00
16	97.78	99.44	97.22	99.44	96.67	100.00	100.00	100.00	100.00	99.44	76.45	100.00	100.00

¹ Running on three GPUs because of the high memory cost according to the setting in [35] (only for Indian Pines dataset).



自适应空谱多尺度网络

实验—IP 数据集



自适应空谱多尺度网络

实验—PU 数据集

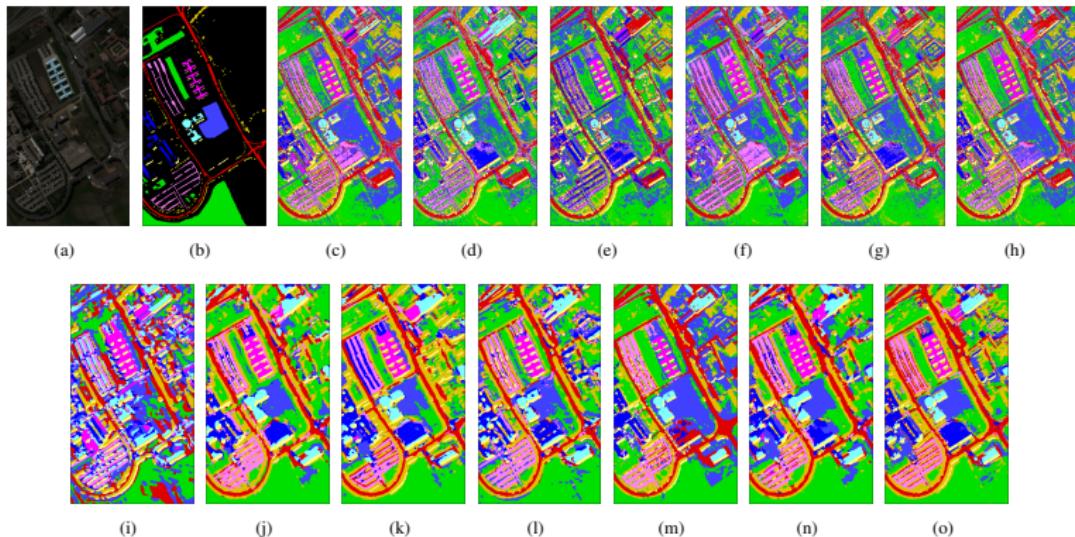
Class	Spectral						Spatial			Joint			
	Metric	SVM	1-DCNN	LSTM-strategy1	LSTM-strategy2	SeMN-scheme1	SeMN-scheme2	2-DCNN	MSCNN	SaMN	3-DCNN	SSRN	SSUN
OA (%)	88.28	75.06	71.46	67.49	81.28	85.62	71.67	94.26	94.56	92.98	96.17	95.36	96.26
	±0.61	±2.62	±6.71	±6.57	±1.58	±2.02	±12.12	±1.03	±1.67	±1.01	±3.27	±0.72	±1.08
AA (%)	90.67	83.65	80.96	72.52	86.61	88.95	80.76	96.01	96.25	95.13	96.30	97.09	98.12
	±0.56	±0.53	±1.86	±6.49	±0.84	±0.94	±4.01	±0.50	±1.10	±0.49	±2.91	±0.42	±0.32
$\kappa \times 100$	84.65	68.44	64.35	58.97	75.81	81.29	64.72	92.45	92.82	90.76	95.00	93.89	95.06
	±0.79	±2.74	±6.71	±7.54	±1.90	±2.50	±12.43	±1.32	±2.15	±1.28	±4.21	±0.93	±1.40
T_{trn} (s)	0.03	58.64	87.60	86.27	126.42	167.19	46.92	55.93	892.33	2602.84	579.45	157.72	976.86
	±0.00	±3.38	±2.92	±3.37	±5.57	±6.60	±1.54	±6.29	±20.92	±164.34	±13.06	±4.41	±22.31
T_{tes} (s)	1.66	1.68	4.98	4.34	2.61	2.92	1.61	3.26	21.43	161.40	21.02	8.37	20.21
	±0.06	±0.76	±0.96	±0.28	±0.20	±0.26	±0.82	±0.67	±2.19	±8.13	±0.78	±0.86	±1.99
1	81.11	72.81	71.33	76.99	81.32	84.53	70.94	91.52	94.22	90.16	99.21	93.73	96.80
2	88.83	68.73	63.40	63.97	78.42	84.14	66.66	92.85	93.45	92.23	99.61	93.74	94.06
3	82.85	78.76	69.16	55.98	80.33	81.40	75.10	93.23	91.51	92.62	95.11	94.33	97.95
4	95.58	89.89	86.45	91.82	94.13	94.07	89.02	97.49	98.49	96.39	89.56	98.49	99.21
5	99.37	99.65	99.33	99.51	98.75	99.04	99.97	99.54	99.97	99.94	99.99	100.00	100.00
6	89.57	75.44	72.70	63.29	75.96	84.96	51.23	98.05	93.03	91.63	92.97	98.53	97.92
7	93.49	90.39	87.89	55.67	91.42	90.89	84.74	97.77	99.33	97.88	97.77	98.96	99.54
8	85.31	77.46	78.64	45.85	79.24	81.68	90.07	95.25	96.81	95.57	92.57	96.56	97.68
9	99.95	99.74	99.85	99.63	99.93	99.81	99.08	98.41	99.47	99.75	99.95	99.47	99.94

○○
○○○
○○○○
○○○○○

○○○○○○○○○○
○○○○○○○○○○
○○○○○○○○○○○○○○●○○
○○○○○○○○○○

自适应空谱多尺度网络

实验—PU 数据集



(a) False color image. (b) Ground truth. (c) SVM. (d) 1-DCNN. (e) LSTM-strategy1. (f) LSTM-strategy2.
 (g) SeMN-scheme1. (h) SeMN-scheme2. (i) 2-DCNN. (j) MSCNN. (k) SaMN. (l) 3-DCNN. (m) SSRN.
 (n) SSUN. (o) ASSMN.

自适应空谱多尺度网络

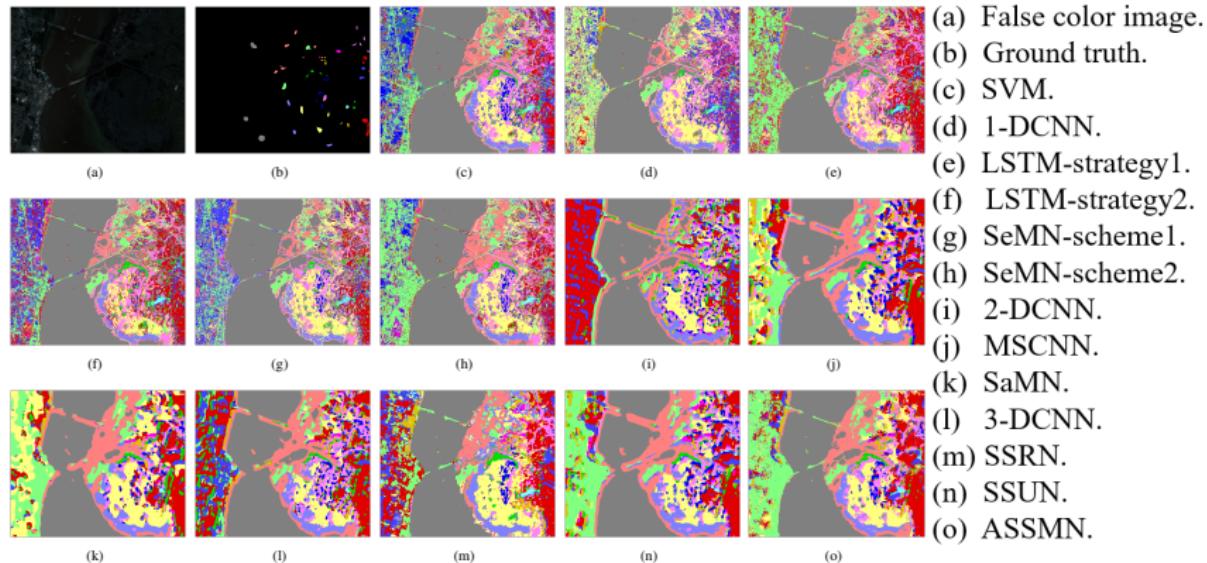
实验—KSC 数据集

Class	Spectral						Spatial			Joint			
	SVM	I-DCNN	LSTM-strategy1	LSTM-strategy2	SeMN-scheme1	SeMN-scheme2	2-DCNN	MSCNN	SaMN	3-DCNN	SSRN	SSUN	ASSMN
OA (%)	90.84	78.44	78.88	77.86	86.03	87.79	93.05	97.75	98.11	97.92	98.30	98.13	98.44
	±0.72	±2.54	±6.18	±4.45	±0.56	±1.83	±0.77	±0.68	±0.62	±0.76	±1.18	±0.74	±0.92
AA (%)	86.48	69.14	70.32	68.13	80.24	82.74	91.40	97.13	97.49	97.31	97.51	97.80	98.00
	±0.68	±3.11	±9.35	±7.57	±0.84	±2.62	±1.09	±0.93	±0.87	±1.09	±1.47	±0.67	±1.03
$\kappa \times 100$	89.80	75.99	76.45	75.24	84.46	86.42	92.26	97.49	97.90	97.68	98.11	97.91	98.27
	±0.79	±2.76	±6.91	±5.00	±0.61	±2.04	±0.86	±0.76	±0.69	±0.84	±1.31	±0.82	±1.02
T_{train} (s)	0.02	68.18	49.27	49.28	64.14	81.69	24.25	40.30	391.65	4616.92	332.95	85.85	472.07
	±0.00	±2.27	±3.00	±4.45	±3.79	±4.34	±1.17	±5.15	±3.38	±204.81	±11.31	±4.74	±7.84
T_{test} (s)	0.17	1.03	1.42	1.32	0.30	0.33	0.98	1.15	3.05	90.30	2.48	1.96	2.27
	±0.01	±0.51	±0.70	±0.55	±0.05	±0.10	±0.46	±0.45	±1.48	±8.19	±0.18	±0.35	±0.30
1	89.73	79.59	83.54	88.01	83.05	84.23	86.15	95.67	96.24	95.71	99.67	95.71	97.09
2	89.14	87.73	72.50	83.59	84.14	88.00	92.68	93.73	95.95	95.91	98.91	96.14	96.91
3	91.68	37.89	56.77	35.39	83.49	86.85	92.33	96.21	95.60	93.58	98.02	95.95	93.88
4	78.07	29.69	46.89	29.04	56.01	63.11	78.60	90.44	93.55	93.42	86.92	93.11	93.25
5	56.85	41.37	40.55	44.93	51.03	58.97	96.44	97.53	93.70	98.08	96.66	98.15	98.15
6	60.82	40.00	37.44	40.19	51.55	53.04	73.33	97.58	97.68	95.27	94.97	98.60	97.73
7	83.85	51.67	59.38	53.44	74.79	76.25	86.04	95.94	97.60	95.83	94.76	97.81	98.85
8	90.59	70.66	59.11	53.79	84.86	85.06	94.78	97.53	98.07	98.93	98.81	97.99	98.98
9	95.95	87.33	79.53	81.60	90.55	93.35	97.10	99.64	99.70	98.83	99.86	99.06	99.72
10	97.10	92.49	93.62	91.34	94.77	96.11	98.58	99.81	99.92	99.92	99.73	99.21	99.97
11	96.64	95.56	97.04	96.85	96.56	96.88	97.49	100.00	100.00	100.00	99.62	100.00	100.00
12	93.79	84.87	87.80	87.51	92.58	93.79	94.69	98.55	99.38	99.49	99.78	99.71	99.47
13	100.00	99.92	99.99	100.00	99.93	99.95	100.00	100.00	100.00	100.00	99.90	100.00	100.00



自适应空谱多尺度网络

实验—KSC 数据集



模型对比及分析

目录

1 研究背景

- 高光谱图像分类
- 存在的问题
- 解决方法
- 研究现状

2 研究路线

3 研究内容

- 多尺度混合补偿网络

■ 混合信息感知网络

■ 自适应空谱多尺度网络

■ 模型对比及分析

4 研究总结

5 参考文献

6 研究成果

7 感谢



模型对比及分析

实验设置

待测试模型：ORI-MSHCN、SS-HPN-LSTM、ASSMN

本节实验数据集：(a) WDC. (b) SA. (c) PC.

- WDC: $307 \times 1280 \times 191$ (移除噪声波段后), 7 类
- SA: $512 \times 217 \times 204$ (移除水吸收波段后), 16 类
- PC: $1096 \times 715 \times 102$, 9 类

训练集：每类随机选 100 个样本



模型对比及分析

模型性能比较—WDC 数据集

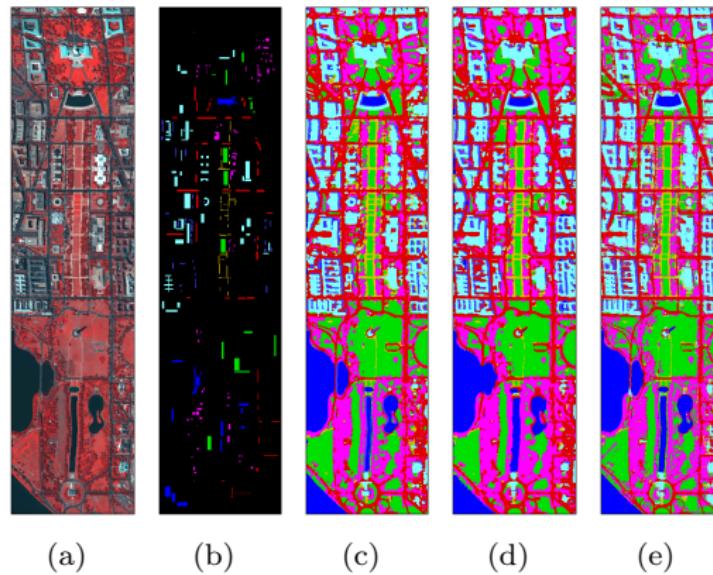
三种网络在 WDC 数据集上的分类结果

	OA(%)	AA(%)	κ (%)
ORI-MSHCN	99.35±0.18	99.33±0.27	99.20±0.23
SS-HPN-LSTM	99.56±0.09	99.53±0.17	99.46±0.11
ASSMN	99.61±0.11	99.60±0.13	99.52±0.14

11

模型对比及分析

模型性能比较—WDC 数据集



三种网络在 WDC 数据集上的分类图。(a) False color image. (b) Ground truth. (c) ORI-MSHCN. (d) SS-HPN-LSTM. (e) ASSMN.



模型对比及分析

模型性能比较—SA 数据集

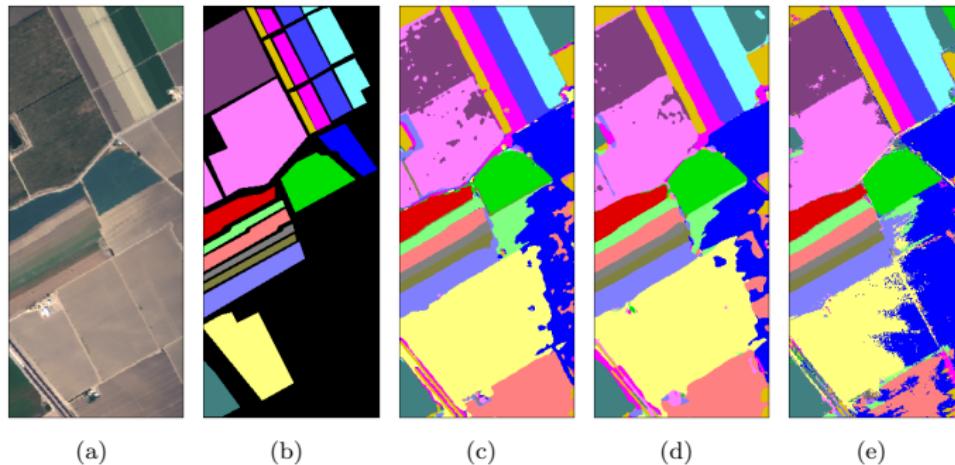
三种网络在 SA 数据集上的分类结果

	OA(%)	AA(%)	κ (%)
ORI-MSHCN	94.95±1.69	98.29±0.47	94.38±1.86
SS-HPN-LSTM	97.98±0.44	99.29±0.13	97.75±0.49
ASSMN	98.32±0.52	99.32±0.23	98.13±0.58



模型对比及分析

模型性能比较—SA 数据集



三种网络在 SA 数据集上的分类图。 (a) False color image. (b) Ground truth. (c) ORI-MSHCN. (d) SS-HPN-LSTM. (e) ASSMN.



模型对比及分析



模型性能比较—PC 数据集

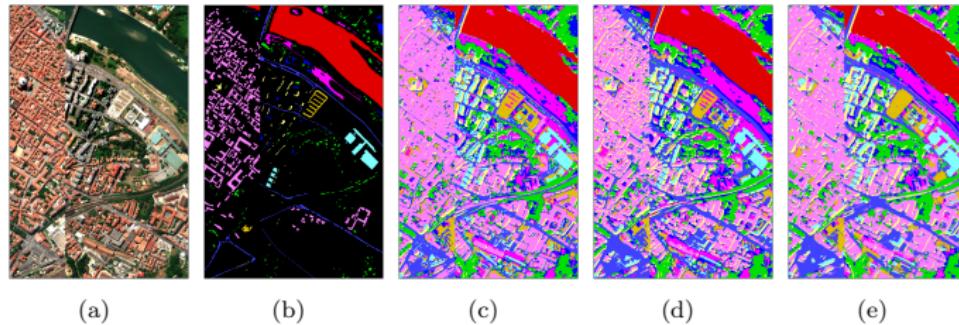
三种网络在 PC 数据集上的分类结果

	OA(%)	AA(%)	κ (%)
ORI-MSHCN	99.48±0.10	98.76±0.20	99.25±0.14
SS-HPN-LSTM	98.85±1.21	97.79±1.59	98.38±1.70
ASSMN	99.47±0.11	99.09±0.10	99.25±0.16

10

模型对比及分析

模型性能比较—PC 数据集



三种网络在 PC 数据集上的分类图。(a) False color image. (b) Ground truth. (c) ORI-MSHCN. (d) SS-HPN-LSTM. (e) ASSMN.



模型对比及分析

模型复杂度比较

三种网络的模型复杂度

模型复杂度	ORI-MSHCN	SS-HPN-LSTM	ASSMN
#Params(M)	33.91	14.55	2.38
FLOPs(M)	331.41	143.11	1066.10



研究总结

- I 介绍了一种可以补偿前向信息传播时细节信息的丢失的同时保留语义信息的多尺度特征提取模块，并在此基础上，提出了一个端到端的空间信息提取网络 MSHCN 进行高光谱图像分类。
- II 介绍了一个可以端到端获取多种特征用于高光谱图像空谱联合分类的网络 SS-HPN，其中主要设计了一个新颖的基于 RNN 的模块从空间层面感受上下文信息。
- III 介绍了一种端到端提取多尺度上下文信息进行高光谱图像分类的自适应分类网络，它包含光谱和空间特征提取两个部分。与先前获得单尺度光谱信息的方法相比，借助于波段分组策略，在光谱部分开发出两种多尺度特征提取方案。在空间部分，凭借 ConvLSTM 获得了空间上下文信息，并且提出了使得不同时间步的输入交流更充分的多维分组策略。还设计出了能够平衡计算效率并可以同时在行列方向进行上下文信息感知的级联式输入序列。在获得光谱和空间特征后，介绍了一种能够考虑两部分特征不同重要性的自适应特征融合模块。
- IV 相比于单纯进行空间多尺度特征提取的 ORI-MSHCN 和利用 LSTM 进行逐方向空间局部上下文信息探索的 SS-HPN-LSTM，ASSMN 结合并进一步拓展了 ORI-MSHCN 和 SS-HPN-LSTM 各自的优点，因而在这些三者中取得了最有力的分类结果，其能够获得更高精度和在地物之间和内部同时具有区分度边缘以及连续表面的分类图，因而对土地覆盖识别、城市规划、环境监测等领域具有重要意义。

参考文献 |

- [1] Y. Chen, Z. Lin, X. Zhao, G. Wang, and Y. Gu, "Deep Learning-Based Classification of Hyperspectral Data," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 7, no. 6, pp. 2094–2107, 2014.
 - [2] T. Li, J. Zhang, and Y. Zhang, "Classification of hyperspectral image based on deep belief networks," in *Proceedings of the IEEE International Conference on Image Processing (ICIP)*, 2014, pp. 5132–5136.
 - [3] Y. Chen, H. Jiang, C. Li, X. Jia, and P. Ghamisi, "Deep Feature Extraction and Classification of Hyperspectral Images Based on Convolutional Neural Networks," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 54, no. 10, pp. 6232–6251, 2016.
 - [4] F. Zhou, R. Hang, Q. Liu, and X. Yuan, "Integrating convolutional neural network and gated recurrent unit for hyperspectral image spectral-spatial classification," in *Proceedings of the Chinese Conference on Pattern Recognition and Computer Vision (PRCV)*, 2018.
 - [5] Z. Feng, R. Hang, Q. Liu, and X. Yuan, "Hyperspectral image classification using spectral-spatial lstms," in *Proceedings of the CCF Chinese Conference on Computer Vision (CCCV)*, 2017.
 - [6] L. Mou, P. Ghamisi, and X. X. Zhu, "Deep recurrent neural networks for hyperspectral image classification," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 55, no. 7, pp. 3639–3655, 2017.
 - [7] Y. Xu, L. Zhang, B. Du, and F. Zhang, "Spectral-spatial unified networks for hyperspectral image classification," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 56, no. 10, pp. 5893–5909, 2018.

参考文献 II

- [8] X. Zhang, Y. Sun, K. Jiang, C. Li, L. Jiao, and H. Zhou, "Spatial sequential recurrent neural network for hyperspectral image classification," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 11, no. 11, pp. 4141–4155, 2018.
 - [9] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, "Going Deeper with Convolutions," *arXiv e-prints*, arXiv:1409.4842, cs.CV, 2014.
 - [10] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, "Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation," *arXiv e-prints*, arXiv:1802.02611, cs.CV, 2018.
 - [11] Z. Niu, W. Liu, J. Zhao, and G. Jiang, "Deeplab-based spatial feature extraction for hyperspectral image classification," *IEEE Geoscience and Remote Sensing Letters*, vol. 16, no. 2, pp. 251–255, 2019.
 - [12] J. Li, X. Zhao, Y. Li, Q. Du, B. Xi, and J. Hu, "Classification of hyperspectral imagery using a new fully convolutional neural network," *IEEE Geoscience and Remote Sensing Letters*, vol. 15, no. 2, pp. 292–296, 2018.
 - [13] Z. Zhong, J. Li, Z. Luo, and M. Chapman, "Spectral-spatial residual network for hyperspectral image classification: A 3-d deep learning framework," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 56, no. 2, pp. 847–858, 2018.
 - [14] M. E. Paoletti, J. M. Haut, R. Fernandez-Beltran, J. Plaza, A. J. Plaza, and F. Pla, "Deep pyramidal residual networks for spectral-spatial hyperspectral image classification," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 57, no. 2, pp. 740–754, 2019.



攻读测绘工程专业硕士学位期间学术成果

- D. Wang, B. Du, L. Zhang, and S. Chu, "Hyperspectral Image Classification Based on Multi-scale Information Compensation," *Remote Sensing Letters*. (Accept).
- D. Wang, B. Du and L. Zhang. "Hyperspectral Image Classification Based on Spatial Contextual Information Perception," *IEEE Geoscience and Remote Sensing Letters*. (Under Review).
- D. Wang, B. Du, L. Zhang, and Y. Xu, "Adaptive Spectral-Spatial Multi-Scale Contextual Feature Extraction for Hyperspectral Image Classification," *IEEE Transactions on Geoscience and Remote Sensing*. (Under Review)



感谢

请各位老师专家批评指正！
感谢这两年，谢谢你们！